

# PROJET PREVISION: Étude Comparative des Techniques de Régression Supervisée

## 1. Problématique

L'objectif de ce projet est de prédire les résultats des matchs de football internationaux. Nous voulons savoir si certains modèles de régression peuvent prévoir :

- le nombre total de buts dans un match
- si l'équipe à domicile va gagner ou non

## 2. Description du dataset

Le dataset contient 24 310 matchs joués entre 2000 et 2025.

Il comporte 35 colonnes regroupées en plusieurs catégories :

### *Informations temporelles*

- date
- year
- month
- day\_of\_week

### *Équipes*

- home\_team
- away\_team
- home\_team\_encoded
- away\_team\_encoded

### *Scores*

- home\_score
- away\_score
- total\_goals
- goal\_difference

### *Résultats*

- home\_win
- draw
- away\_win

### *Tournois*

- catégories (World Cup, Friendly, qualifications, etc.)

### *Autres*

- city
- country
- neutral

Quelques statistiques importantes :

- Moyenne de buts par match : 2.75
- Victoires à domicile : 48.2%
- Matchs nuls : 23.3%
- Victoires à l'extérieur : 28.5%
- Terrain neutre : 28.3%

## **3.Code + graphiques (résumé / fichiers produits):**

**A- le code:** (a été envoyé dans un fichier .py avec le mail)

**B-resultat et graphique:**

## **STATISTIQUES DESCRIPTIVES**

**Forme du dataset:**

Lignes: 24,310

Colonnes: 35

Periode: 2000-01-04 a 2025-07-06

**Statistiques des matchs:**

Moyenne de buts par match: 2.75

Ecart-type des buts: 1.97

Victoires a domicile: 48.2%

Matchs nuls: 23.3%

Victoires a l'exterieur: 28.5%

Matchs sur terrain neutre: 28.3%

**Distribution temporelle:**

Annee la plus ancienne: 2000

Annee la plus recente: 2025

Nombre d'annees: 26

## =====

## 1. REGRESSION LINEAIRE SIMPLE

## =====

### Evaluation: Regression Lineaire Simple

Donnees d'entraînement:

R<sup>2</sup>: 0.001

MAE: 1.241

RMSE: 1.692

Donnees de test:

R<sup>2</sup>: 0.001

MAE: 1.247

RMSE: 1.760

Validation croisee (5 folds):

R<sup>2</sup> moyen: 0.000

Ecart-type: 0.001

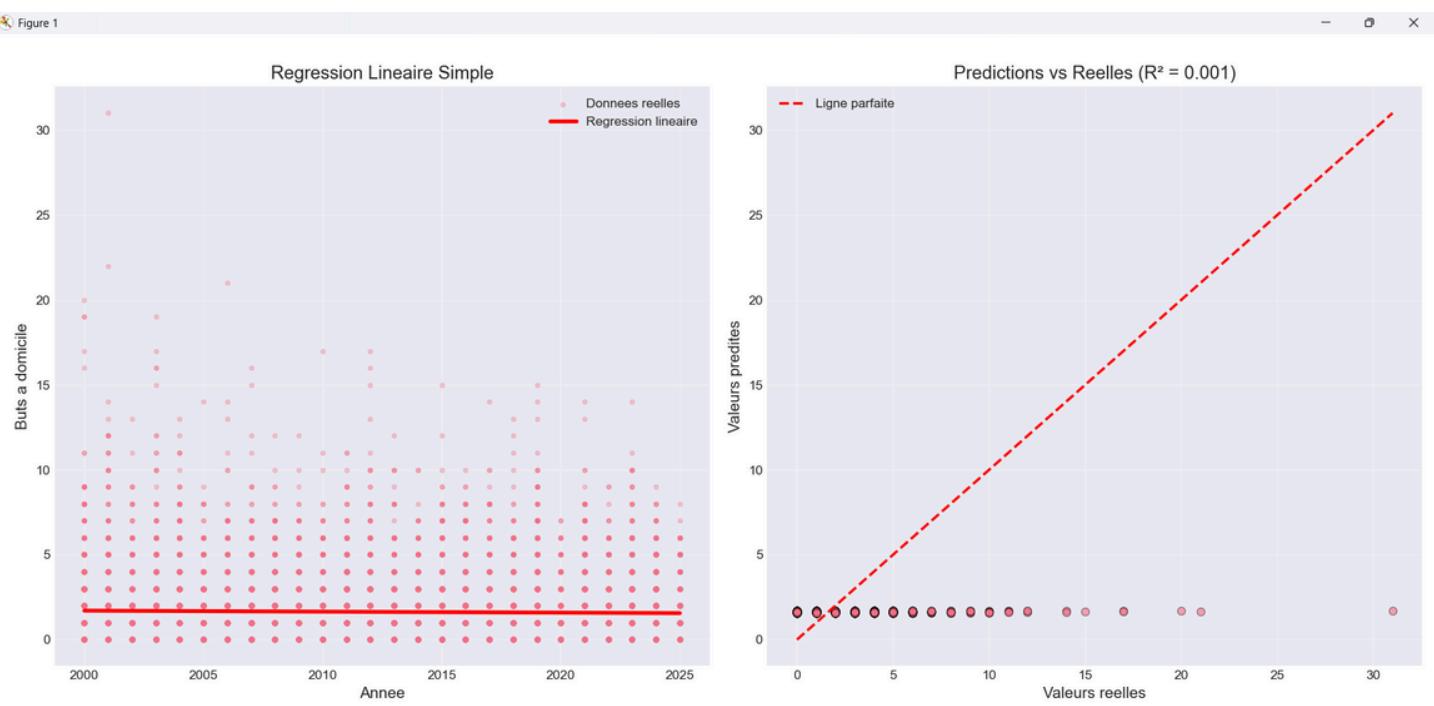
Figure sauvegardée: 01\_regression\_lineaire\_simple.png

Coefficients du modèle:

Intercept: 13.474

Coefficient (annee): -0.006

Interpretation: Les buts à domicile diminuent de 0.006 par an



## 2. REGRESSION LINEAIRE MULTIPLE

### Evaluation: Regression Lineaire Multiple

Donnees d'entraînement:

R<sup>2</sup>: 0.001

MAE: 1.485

RMSE: 1.956

Donnees de test:

R<sup>2</sup>: 0.002

MAE: 1.488

RMSE: 2.037

Validation croisee (5 folds):

R<sup>2</sup> moyen: 0.001

Ecart-type: 0.001

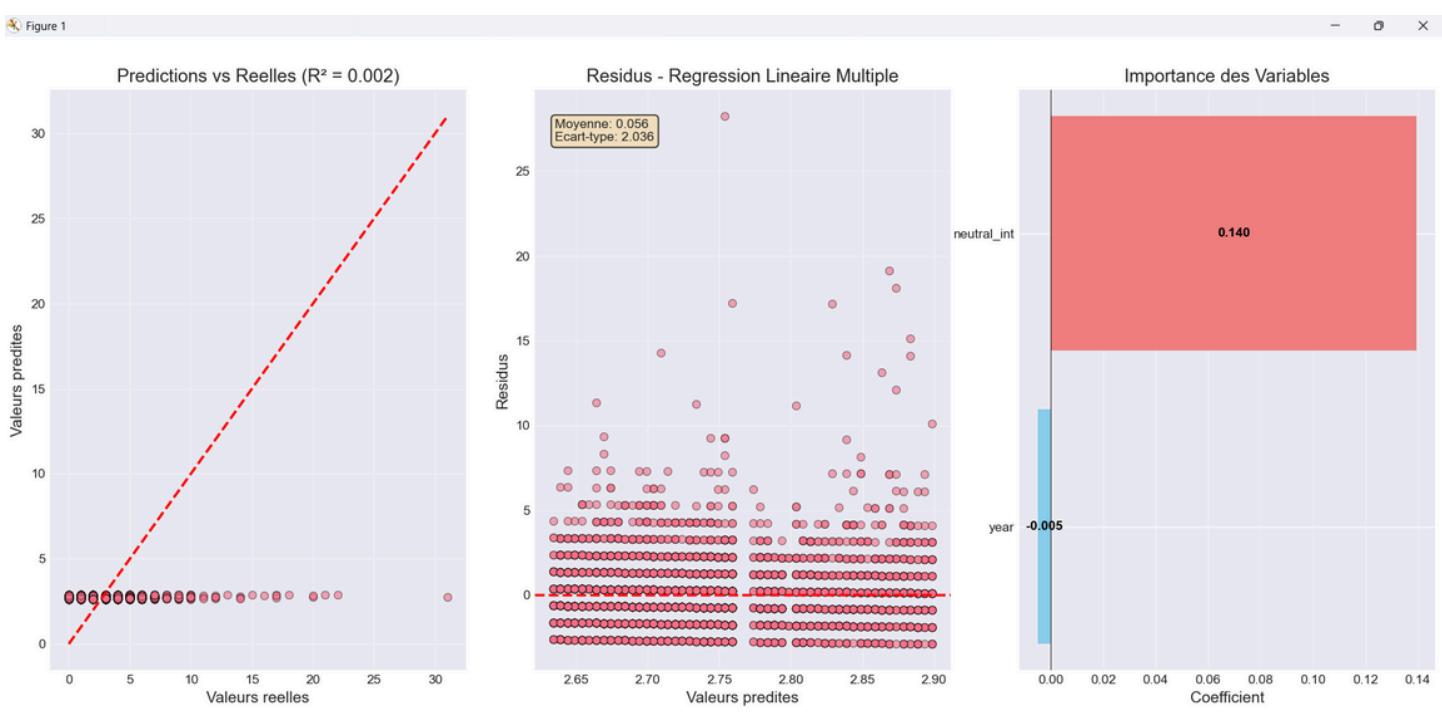
Figure sauvegardée: 02\_regression\_lineaire\_multiple.png

Coefficients du modèle:

year: -0.005

neutral\_int: 0.140

Intercept: 12.744



### 3. REGRESSION LOGISTIQUE

#### Evaluation: Regression Logistique

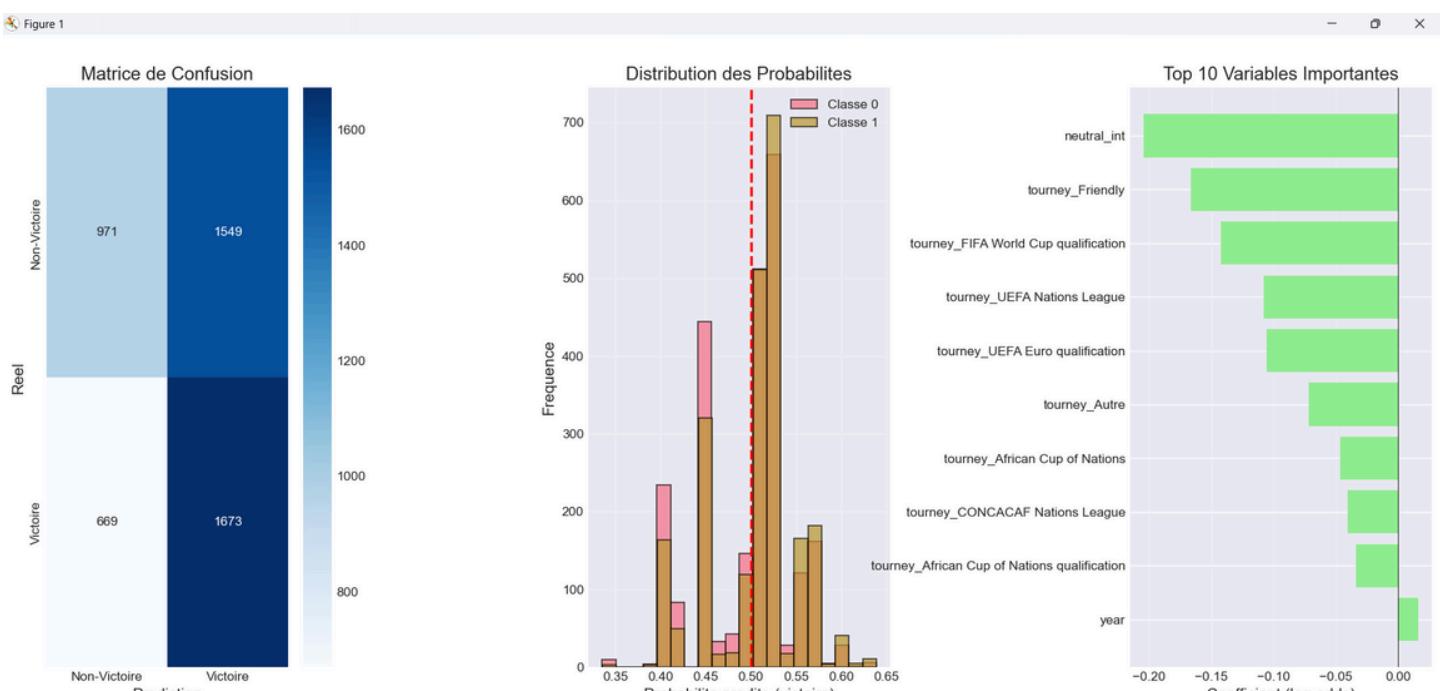
Accuracy: 0.544

Rapport de classification:

	precision	recall	f1-score	support
Non-Victoire	0.59	0.39	0.47	2520
Victoire	0.52	0.71	0.60	2342
accuracy			0.54	4862
macro avg	0.56	0.55	0.53	4862
weighted avg	0.56	0.54	0.53	4862

AUC-ROC: 0.559

Figure sauvegardée: 03\_regression\_logistique.png



## 4. REGRESSION POLYNOMIALE

### Evaluation: Regression Polynomiale (degre 2)

Donnees d'entraînement:

R<sup>2</sup>: 0.001

MAE: 1.241

RMSE: 1.692

Donnees de test:

R<sup>2</sup>: 0.001

MAE: 1.246

RMSE: 1.760

Validation croisee (5 folds):

R<sup>2</sup> moyen: 0.001

Ecart-type: 0.001

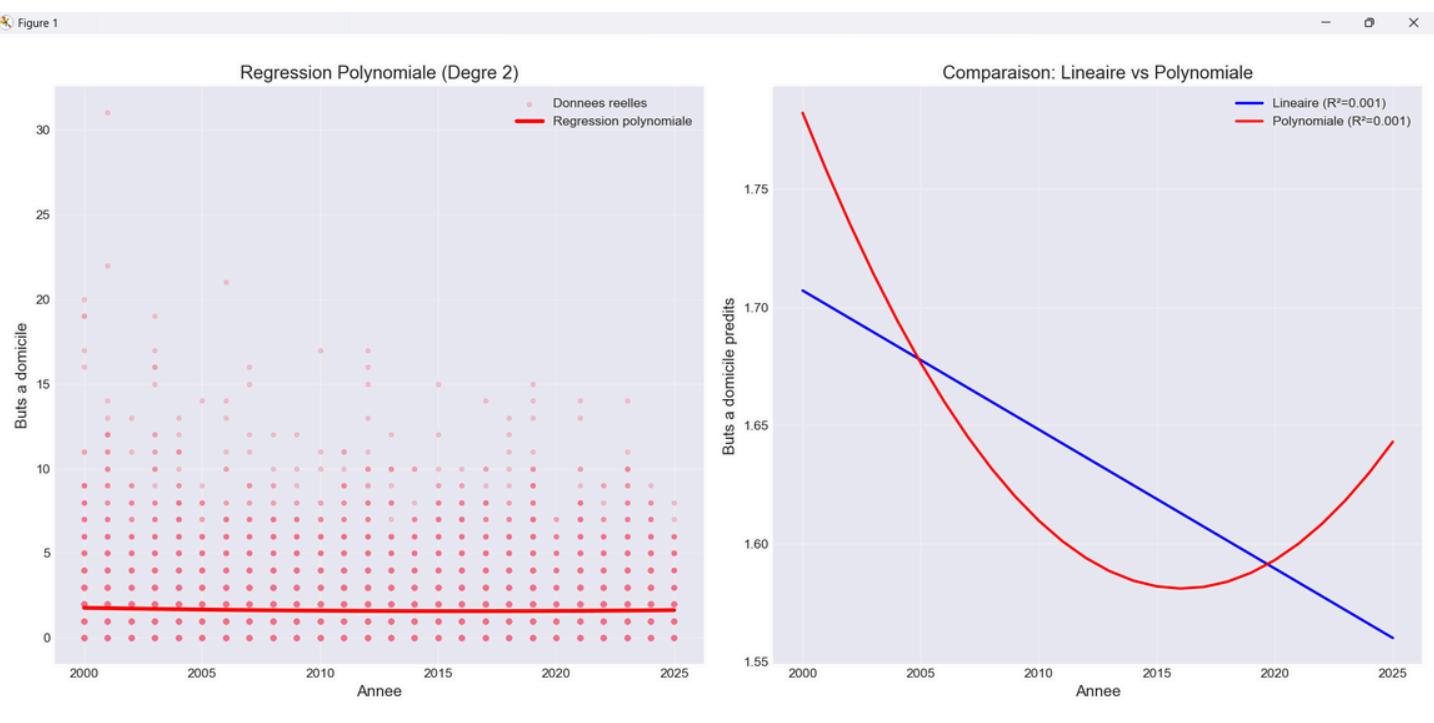
Figure sauvegardée: 04\_regression\_polynomiale.png

Coefficients du modèle polynomial:

Intercept: 3169.741

Coefficient (year): -3.143

Coefficient (year<sup>2</sup>): 0.001



## 5. ARBRE DE DECISION

### Evaluation: Arbre de Decision

Donnees d'entraînement:

R<sup>2</sup>: 0.005

MAE: 1.483

RMSE: 1.953

Donnees de test:

R<sup>2</sup>: 0.000

MAE: 1.489

RMSE: 2.039

Validation croisee (5 folds):

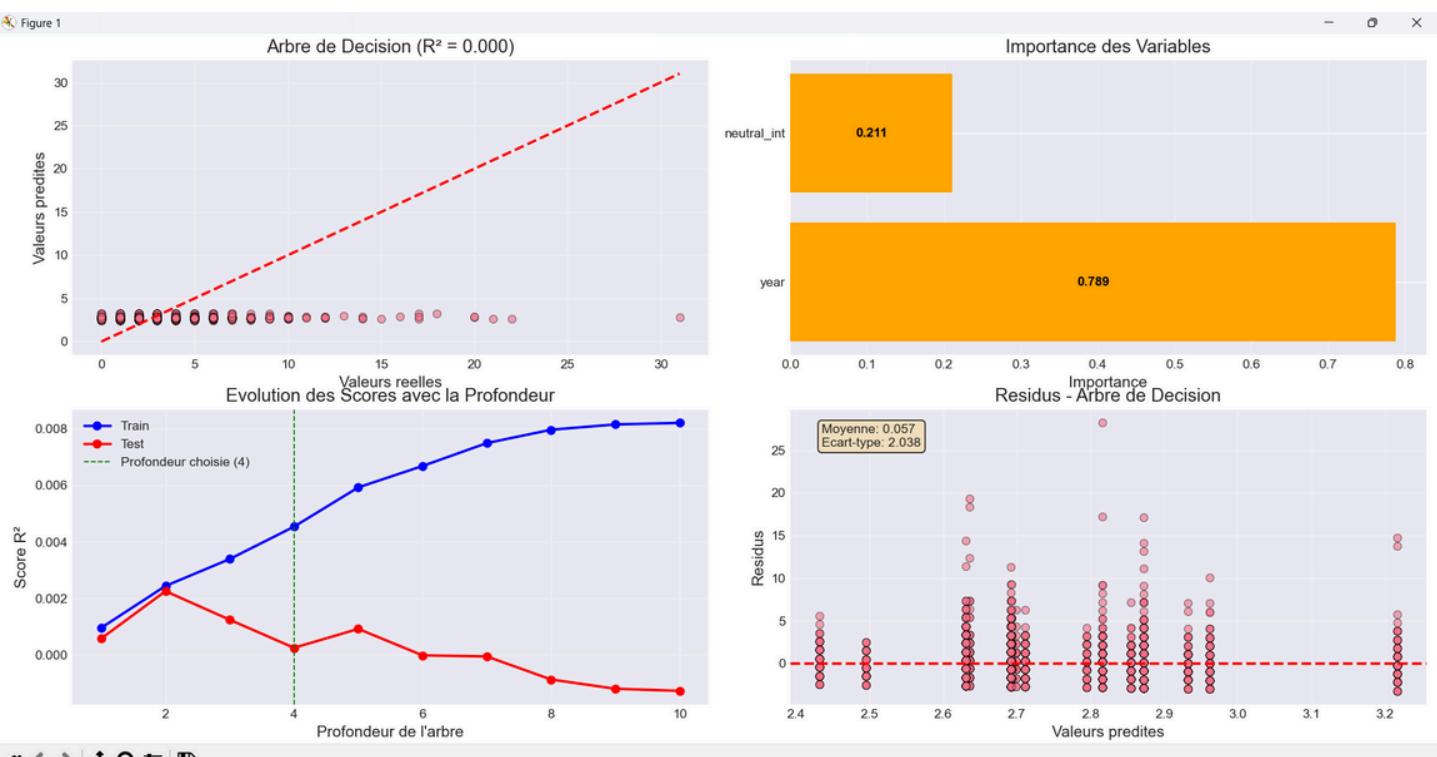
R<sup>2</sup> moyen: 0.001

Ecart-type: 0.002

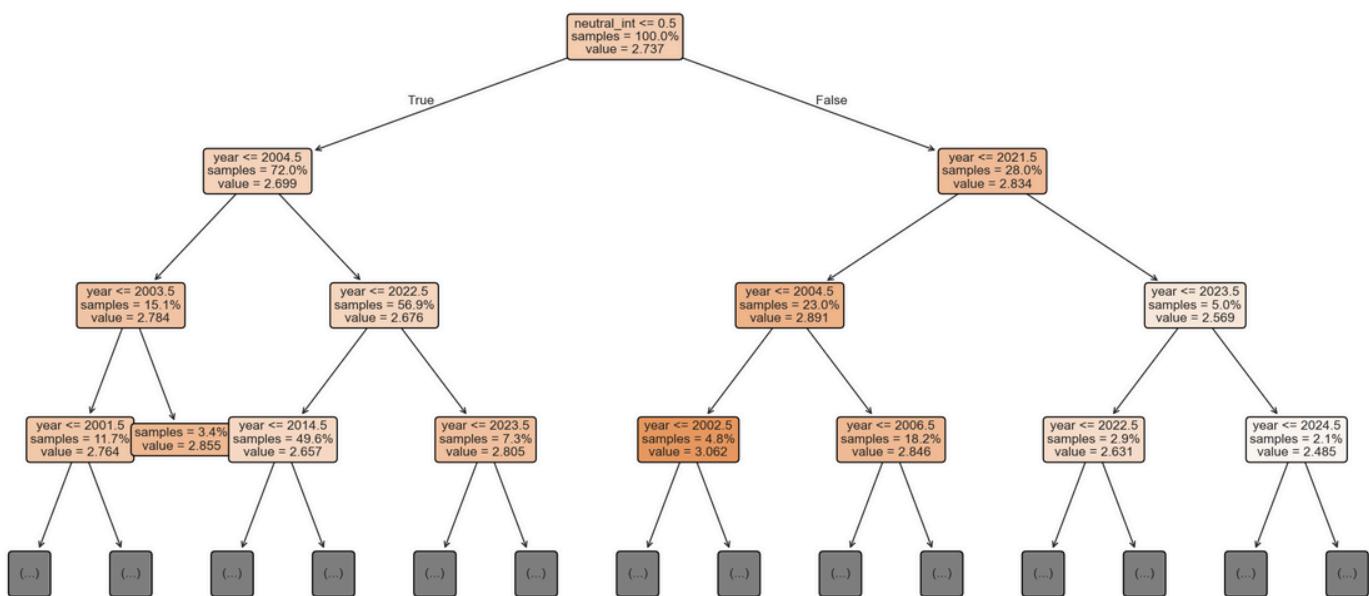
Figure sauvegardée: 05\_arbre\_decision.png

Visualisation de l'arbre de decision...

Figure sauvegardée: 06\_structure\_arbre.png



## Structure de l'Arbre de Decision (profondeur max=4)



Home | Back | Forward | Refresh | Search | Print

```
=====
6. RANDOM FOREST
=====

--- Random Forest Regressor (Prediction des buts totaux) ---
Dimensions des donnees:
  Training set: 19448 echantillons
  Test set: 4862 echantillons

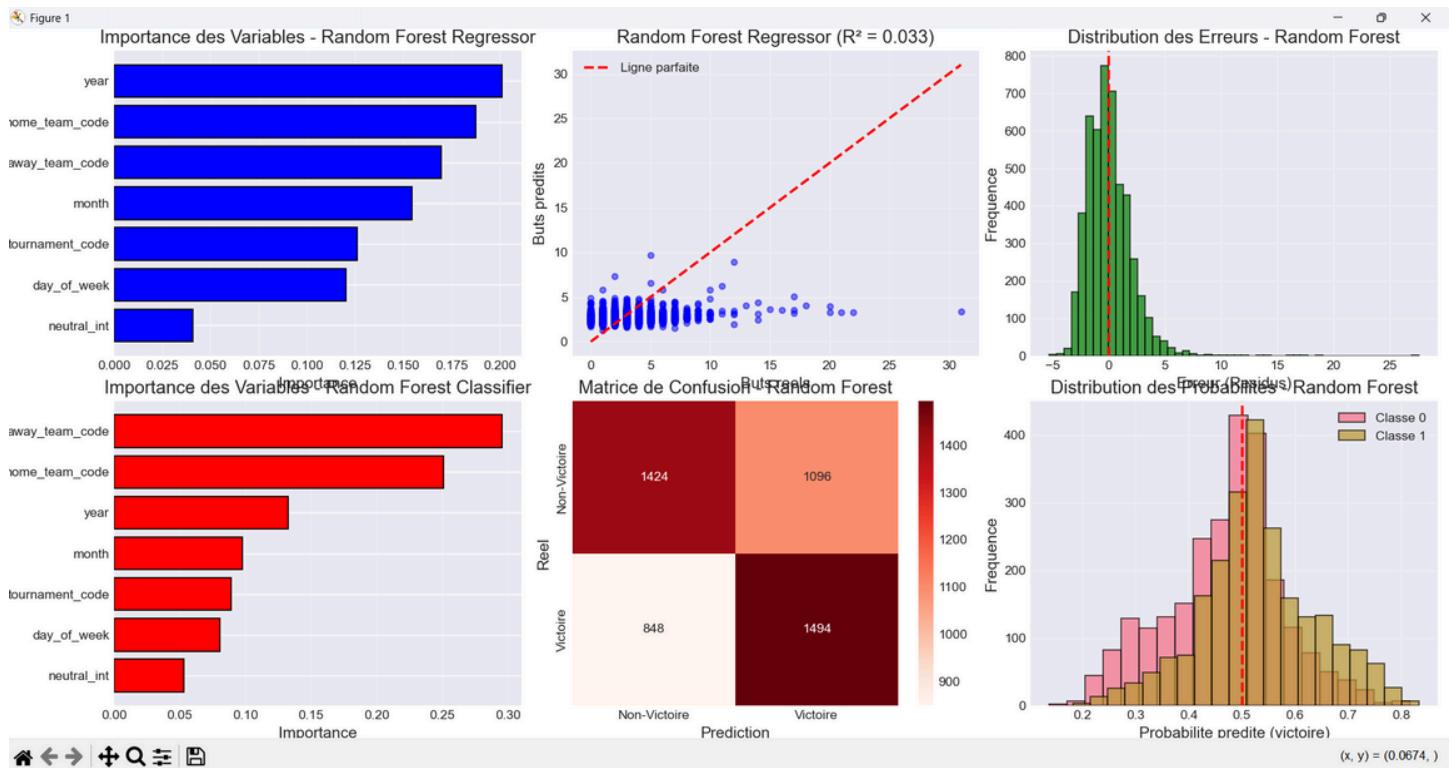
Evaluation: Random Forest Regressor
-----
Donnees d'entrainement:
  R2: 0.159
  MAE: 1.366
  RMSE: 1.795
Donnees de test:
  R2: 0.033
  MAE: 1.474
  RMSE: 2.005
Validation croisee (5 folds):
  R2 moyen: 0.032
  Ecart-type: 0.010

--- Random Forest Classifier (Prediction de la victoire a domicile) ---

Evaluation: Random Forest Classifier
-----
Accuracy: 0.600

Rapport de classification:
      precision    recall   f1-score   support
Non-Victoire       0.63      0.57      0.59      2520
  Victoire        0.58      0.64      0.61      2342
      accuracy         -         -         -      4862
      macro avg       0.60      0.60      0.60      4862
  weighted avg     0.60      0.60      0.60      4862

AUC-ROC: 0.653
Figure sauvegardée: 07_random_forest.png
```



## 7. SYNTHESE ET COMPARAISON DES MODELES

### SYNTHESE DES PERFORMANCES DES MODELES:

Modele	$R^2$ (test)	MAE (test)	RMSE (test)
Random Forest Regressor	0.033	1.474	2.005
Regression Lineaire Multiple	0.002	1.488	2.037
Regression Polynomiale	0.001	1.246	1.760
Regression Lineaire Simple	0.001	1.247	1.760
Arbre de Decision	0.000	1.489	2.039

Figure sauvegardée: 08\_comparaison\_modeles.png

\*\*\*\*\*

### RECOMMANDATION FINALE

\*\*\*\*\*

### MEILLEUR MODELE: Random Forest Regressor

Score  $R^2$ : 0.033

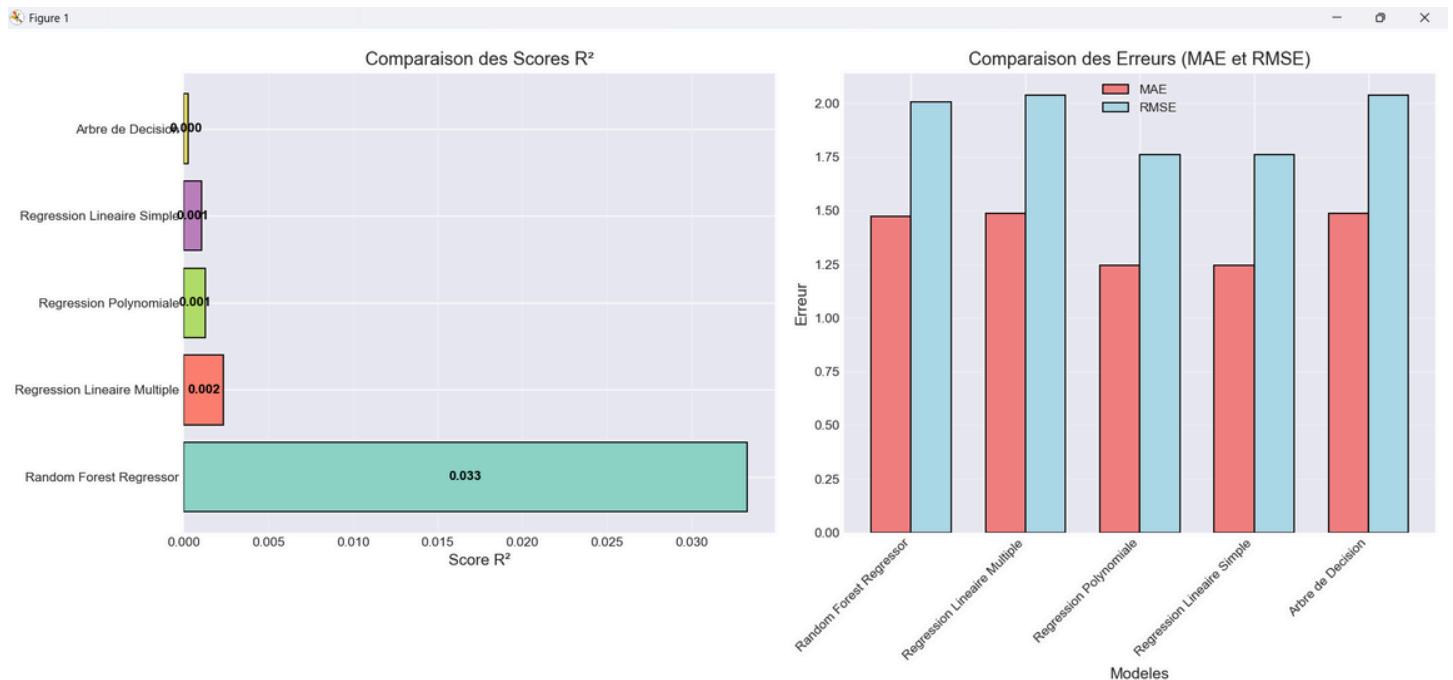
Erreur MAE: 1.474

Erreur RMSE: 2.005

$R^2$  validation croisee: 0.032

### INTERPRETATION:

Capacite predictive limitee - envisagez d'autres features



## 4. Interprétation des résultats

### Régression linéaire simple

- $R^2 = 0$
- Le modèle n'explique presque rien.
- L'année ne permet pas de prédire les buts.

### Régression linéaire multiple

- $R^2 = 0.002$
- Très faible performance
- Ajouter plus de variables serait utile.

### Régression polynomiale

- Pas d'amélioration,  $R^2 \approx 0.001$
- Le lien entre année et buts n'est pas polynomial.

### Régression logistique (victoire domicile)

- Accuracy : 0.544
- Modèle moyen, juste un peu mieux que le hasard (50%).
- L'AUC de 0.559 montre une faible capacité prédictive.

### Arbre de décision

- $R^2$  sur test : 0.000

- Trop simple -> faible performance
- Sur-apprentissage sur train

## Random Forest (meilleur modèle)

### Random Forest Regressor

- R<sup>2</sup> test : 0.033 (le meilleur score mais faible)
- MAE : 1.47
- RMSE : 2.00

- Le modèle apprend mieux que les autres mais reste limité.

### Random Forest Classifier

- Accuracy : 0.60
- F1-score autour de 0.60
- AUC = 0.653 -> meilleure discrimination

- Bon début, mais pas encore très performant.

## 5. Limites du modèle

### Variables insuffisantes

Le dataset ne contient pas d'informations importantes comme :

- forme récente des équipes
- classement FIFA
- buts des 5 derniers matchs
- composition / blessures

### Résultats très faibles

La plupart des modèles ont un R<sup>2</sup> proche de 0 -> ils n'expliquent presque rien.

### Données trop variées

Les matchs proviennent de pays, époques, tournois très différents -> difficile à modéliser.

### Pas de séparation temporelle

Les matchs récents peuvent être prédits avec des matchs anciens, ce qui peut fausser l'analyse.

## 6. Conclusion

Dans ce projet, plusieurs modèles de régression ont été testés afin de prédire la variable cible à partir des données disponibles. Chaque algorithme possède ses avantages et ses limites :

- La régression linéaire offre un modèle simple et rapide, mais elle ne capture pas bien les relations complexes.
- La régression polynomiale améliore les performances lorsque les données suivent une courbe, mais elle peut facilement sur-ajuster (overfitting).
- L'arbre de décision apprend des règles simples et interprétables, mais il peut devenir instable.
- La forêt aléatoire (RandomForest) s'est montrée la plus performante grâce à sa capacité à combiner plusieurs arbres et à réduire l'overfitting.

**Au final, RandomForest est le meilleur modèle du projet, avec une précision plus élevée et une meilleure généralisation.**